Introduzione alla Bioinformatica

Davide Cozzi
davide.cozzi@unimib.it

Università degli Studi di Milano-Bicocca

Lezione 1

Argomenti Laboratorio

Un assaggio di bioinformatica "pratica"

- Formati file
- Tool e librerie per leggere file bioinformatici
- Tool per le task più comuni (assemblaggi e allineamenti)
- Breve introduzione alla pangenomica e ai tool correlati
- Creazione di pipeline bioinformatiche

Argomento teorico bonus (se avremo tempo)

Trasformata di Burrows–Wheeler Posizionale

Qualche Informazione Pratica

Un laboratorio in aula

- Portate il pc se potete
- Per praticità lavorerò su Gnu/Linux, non garantisco che i tool che vedremo funzionino altrove, anche se useremo Conda/Mamba
- Assumo conoscenze basi di uso della shell (muoversi tra le cartelle, visualizzare files, etc...)
- Potrebbero tornare comode conoscenze base di C/C++/Python

Uso di Base della shell

- Documentazione (`man`)
- Navigare e gestire il filesystem (`ls`, `cd`, `mv`, `cp`, `rm`)
- Visualizzare file (`cat`, `most`, `less`)
- Modificare file (`nano`, `(n)vi(m)`)
- Gestire e formattare l'output (`grep`, `cut`, `column`)
- Pipe e redirezione (`>`, `<`, `|`)
- Altre utility (`history`, `curl`, `wget`, `make`, `cmake`, `git`)

Gestione Pacchetti: Conda e Mamba

Conda (e Mamba)

- Gestore di env e pacchetti
- Permette di gestire comodamente dipendenze, senza dover compilare etc..., e avere ambienti specifici per ogni contesto
- Ormai ci sono canali per tutte le tematiche, bioconda contiene migliaia di tool bioinformatici

```
conda/mamba create -n progetto -c bioconda <tools>
```

Formati Biologici per Sequenze

- **FASTA**: puro testo, solo sequenze.
- **FASTQ**: sequenze + qualità (output più comune dei sequenziatori).

Il Formato FASTA

Struttura

File di puro testo.

- **Header:** inizia “>”.
- **Sequenza:** nucleotidi (su una o più righe, solitamente max 80 basi).

Esempio (multi-FASTA)

```
>seq1_nome info_aggiuntive
ATGCGTACGTTAGCTAGCTAGCTAGCTAG
CTAGCTAGCTAGCTAGC
>seq2_nome
GCGCGCGCGCGCGCGCGCGCGCGCGCGCGC
```

Volendo si può usare l’alfabeto delle proteine

L'Indice FASTA (File `.fai`)

Accesso Rapido

Permette di estrarre istantaneamente una specifica sequenza (o una sua porzione) senza dover leggere tutto il file FASTA in memoria.

Struttura (5 colonne separate da Tab)

1. **NAME:** Nome della sequenza (dall'header).
2. **LENGTH:** Lunghezza totale in basi.
3. **OFFSET:** Posizione (in byte) in cui inizia la sequenza nel file.
4. **LINEBASES:** Numero di basi per ogni riga.
5. **LINEWIDTH:** Byte per riga (inclusi i caratteri di "a capo").

Esempio file `.fai`

```
seq1_nome_sequenza 46 30 29 30
seq2_nome_sequenza 30 95 30 31
```

Il Formato FASTQ

Struttura

Estende il FASTA. Richiede esattamente **4 righe** per sequenza:

1. **Header:** inizia con "@".
2. **Sequenza:** su una singola riga.
3. **Separatore:** solitamente "+", eventualmente con altre informazioni opzionali.
4. **Qualità:** caratteri ASCII (es. "!" = min, "~" = max).

Esempio FASTQ

```
@SEQ_ID_1
GATTTGGGGTTCAAAGCAGTATCGATCAAATAGTAAA
+
!''*((((***+))%%%++)(%%%%).1***-+*''))
```

Calcolo della Qualità (Phred Score)

La Formula

La qualità Q è legata alla probabilità di errore P nel riconoscimento della singola base azotata:

$$Q = -10 \log_{10}(P)$$

Codifica ASCII

Per occupare un solo byte per nucleotide, Q viene convertito in un carattere ASCII sommandogli una costante (lo standard è 33):

$$Carattere = ASCII(Q + 33)$$

Significato di "+"

- Nella tabella ASCII, "+" corrisponde al valore 43
- Calcoliamo il Phred Score: $Q = 43 - 33 = 10$
- Probabilità di errore: $10 = -10 \log_{10}(P) \rightarrow P = 10^{-1} = 0.1$
- C'è il **10%** di probabilità che la base sia errata.

Aplotipi

```
CTCACTTAGAGGGGCTCTCGACCGTGTCCAGACACTGG   Reference
CTCACTTAGAGGAGCTCTCGACCGTGTCCAGACACTGG
CTCACTTAGAGGAGCTCTCGACCGTGTCCAGACACTGG
CTCGCTTAGAGGGGCTCTCGACCGTGTCCAGACACTGG
CTCACTTAGAGGGGCTCTCGACCGTGTCCAGACACTGC
CTCACTTAGAGGGGCTCTCGACTGTGTCCAGACACTGG
```

A/G	G/A	C/T	G/C	
0	1	0	0	0100
0	1	0	0	0100
1	0	0	0	1000
0	0	0	1	0001
0	0	1	0	0010

Il Formato VCF (Variant Call Format)

Cos'è il VCF?

Nato nel 2011 per il *1000 Genomes Project*. Memorizza le **varianti genomiche** (aplotipi) rispetto a una sequenza di riferimento.

Struttura del File

- **Header:** righe che iniziano con "##". Contengono metadati e descrizioni dei campi.
- **Intestazione Colonne:** una singola riga che inizia con "#" (es. `#CHROM`).
- **Dati:** almeno **8 colonne obbligatorie** tabulate.

Le Colonne del VCF

Le 8 Colonne Obbligatorie

CHROM (cromosoma), **POS** (posizione), **ID**, **REF** (base di riferimento), **ALT** (base alternativa), **QUAL** (score di qualità), **FILTER** (passato o scartato), **INFO** (dati aggiuntivi).

Genotipi, teoricamente opzionali ma in pratica sempre presenti

Colonne aggiuntive per definire il **FORMAT** (es. **GT** per Genotipo, ovvero la coppia di aplotipi materno e paterno) e i dati specifici per ogni campione analizzato.

Esempio VCF unphased (aplotipi non distinti prima e distinti poi)

```
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT sample1
chr1 12345 rs1 A T 50 PASS DP=10 GT 0/1
chr1 12346 rs2 G T,G 50 PASS DP=10 GT 0|1
```

I Campi del VCF (1/3): Coordinate e ID

CHROM e POS

Indicano l'esatta posizione della variante rispetto al genoma di riferimento.

- **CHROM:** Nome del cromosoma o del contig (es. `chr1`, `22`, `contig_1`).
- **POS:** Posizione numerica esatta (1-based).

ID

Identificativo univoco della variante, utile se è già nota in letteratura.

- Spesso si usano gli ID del database dbSNP (es. `rs123456`).
- Se la variante è nuova o l'ID è sconosciuto, si usa un semplice punto ("`.`").

I Campi del VCF (2/3): Variante e Qualità

REF e ALT

Descrivono fisicamente il cambiamento molecolare:

- **REF:** La base (o le basi) presenti sul genoma di riferimento (es. `A`).
- **ALT:** La base mutata trovata nel campione (es. `T`). Può contenere più alleli separati da virgola (es. `T,C`) nel caso multiallelico.

QUAL e FILTER

Indicano l'affidabilità del variant calling:

- **QUAL:** Punteggio di qualità in scala Phred (esattamente come nel FASTQ).
- **FILTER:** Contiene "`PASS`" se la variante è ritenuta vera, altrimenti riporta il codice del filtro fallito (es. `LowQual`) o si usa un semplice punto ("`.`").

I Campi del VCF (3/3): INFO e Genotipo

INFO

Un campo molto flessibile che contiene coppie chiave-valore con metadati generali sulla variante.

- *Esempi:* `DP=100` (depth dell'allineamento), `AF=0.5` (allele frequency per quella variante).

FORMAT e Colonne Campioni

Definiscono lo stato specifico per ogni individuo sequenziato:

- **FORMAT:** Elenca le metriche misurate (es. `GT:DP` $\rightarrow$ genotipo : depth).
- **Sample:** I valori effettivi (es. `0/1:30`).
- *Nota sul Genotipo (GT):* `0` indica il REF, `1` indica il primo ALT. Quindi `0/1` significa **eterozigote**.

Il Formato BCF (Binary VCF)

Perché il BCF?

I file VCF testuali possono diventare giganteschi (centinaia di Gigabyte) quando si analizzano migliaia di campioni. Il **BCF** è la sua versione binaria.

Vantaggi Principali

- **Spazio:** occupa molto meno spazio su disco essendo compresso in formato binario.
- **Velocità:** più rapido da leggere un formato binario leggero piuttosto che parsare centiania di gb di file testuale.

Indicizzazione: VCF e BCF

L'indice permette di estrarre istantaneamente le varianti in una specifica regione (es. un singolo gene) senza leggere l'intero file.

Come si indicizzano?

- **VCF:** deve prima essere compresso a blocchi (es. `bgzip` → `.vcf.gz`). Poi si crea l'indice con tool come `tabix`, generando un file `.tbi` o `.csi`.
- **BCF:** si indicizza direttamente generando un file `.bcf.csi`.

Il Formato SAM (Sequence Alignment Map)

Cos'è il SAM?

Introdotto nel 2009, è lo standard per memorizzare gli **allineamenti** contro un genoma di riferimento.

Struttura del File

- **Header:** righe che iniziano con "@" (informazioni sul riferimento e sui programmi usati).
- **Dati di Allineamento:** ogni riga è una read allineata.
- **Formato: 11 colonne obbligatorie** (separate da tab) + campi opzionali.

I Campi del SAM (1/2): Posizione e CIGAR

Identità e Posizione (Col. 1-4)

1. **QNAME:** Nome della read (identico al fasta/q).
2. **FLAG:** Numero intero che codifica il tipo di allineamento (es. reverse, paired etc...).
3. **RNAME:** Nome del cromosoma di riferimento.
4. **POS:** Posizione esatta di inizio del mapping (1-based).

Qualità e Struttura (Col. 5-6)

5. **MAPQ:** Qualità dell'allineamento.
6. **CIGAR:** Stringa alfanumerica che descrive la struttura dell'allineamento.

Focus: La Stringa CIGAR

Concise Idiosyncratic Gapped Alignment Report

Il CIGAR riassume la read si allinea al reference.

Esempi di CIGAR

- `100M`: 100 basi allineate perfettamente.
- `50M2I48M`: 50 basi allineate, 2 basi **Inserite** rispetto al reference, 48 basi allineate.
- `10M5D90M`: 10 basi allineate, 5 basi **Delete** (mancanti nella read), 90 basi allineate.

Focus: La Stringa CIGAR (Estesa)

Operatori Base

- `M` (Match): base allineata.
- `I` (Insertion): base presente nella read ma assente nel reference.
- `D` (Deletion): base assente nella read ma presente nel reference.

Altri Operatori

- `N` (Skipped region): regione saltata (tipico dello splicing negli RNA-seq, per gli introni).
- `S` (Soft clipping): basi tagliate dall'allineamento ma *presenti* nella colonna SEQ.
- `H` (Hard clipping): basi tagliate e *rimosse* dalla sequenza.

I Campi del SAM (2/2): Dati e Opzioni

Read paired (Col. 7-9)

Informazioni sulla read mate nel paired-end:

- **RNEXT & PNEXT:** riferimento e posizione del mate.
- **TLEN:** distanza totale tra le due read.

Sequenza e Campi Opzionali (Col. 10-11+)

- **SEQ & QUAL:** la sequenza nucleotidica e la sua qualità ASCII (esattamente come nel FASTQ).
- **Campi Opzionali:** tag nel formato `TAG:TIPO:VALORE`, ad esempio i per intero o z per stringa, (es. `NM:i:2` $\rightarrow$ 2 mismatch).

Esempio di un Record SAM

Riga di Allineamento (11 Colonne + Opzionali)

```
READ_01  0  chr1  1024  60  5M2I3M  * 0  0  ACTGGTGCGC  !''*((((** NM:i:0
```

Decodifica dei Campi

1. **QNAME:** `READ_01` (Nome del frammento)
2. **FLAG:** `0` (Read singolo, mappato sul filamento forward)
3. **RNAME & POS:** `chr1`, pos. `1024`
4. **MAPQ:** `60` (Alta confidenza di mappatura)
5. **CIGAR:** `5M2I3M` (5 allineate, 2 inserite, 3 allineate)
6. **RNEXT, PNEXT, TLEN:** `*` e `0` (Nessua read paired/mate)
7. **SEQ & QUAL:** `ACTGGTGCGC` e `!''*((((**`
8. **TAG Opzionale:** `NM:i:0` (0 mismatch nell'allineamento)

Dal SAM al BAM: Ordinamento e Indici

Il Formato BAM (Binary Alignment Map)

I file SAM testuali sono enormi. Il **BAM** è la sua controparte binaria, fortemente compressa e leggera da elaborare.

Prerequisito per l'indicizzazione: sorting

Prima di poter accedere rapidamente ai dati, il BAM deve essere **ordinato** (solitamente per posizione genomica, o per nome del read).

L'Indice (.bai)

- Come per i VCF, genera un file indice (es. `file.bam.bai`).
- Permette l'accesso immediato alle letture che coprono uno specifico gene o variante, senza scorrere miliardi di read.

Dal GFF al GTF

Lo standard è il **GTF** (Gene Transfer Format, o GFF2), che sostituisce il formato **GFF** (General Feature Format), ideato nel 1998 al Sanger Institute, ormai deprecato.

A cosa serve?

Non contiene le sequenze del DNA, ma le **annotazioni genomiche** per capire cosa c'è in una determinata regione del genoma (es. dove inizia e finisce un gene o un esone).

I Campi del GTF (9 Colonne)

Struttura (Separate da Tab)

1. **seqname:** nome del cromosoma o contig (es. `chr1`).
2. **source:** tool o database di origine (es. `HAVANA`, `Ensembl`).
3. **feature:** annotazione (`gene`, `transcript`, `exon`, `CDS`).
4. **start** e **end:** coordinate genomiche di inizio e fine (in base 1).
5. **score:** punteggio di confidenza (o "`.`" se non applicabile).
6. **strand:** direzione del filamento: "+" (forward) o "-" (reverse).
7. **frame:** posizione della base nel codone (0, 1, 2) o "`.`".
8. **attributes:** lista di coppie chiave-valore separate da punto e virgola (es. `gene_id "ENSG...";`) per informazioni opzionali.

Le Feature del GTF

Gene e trascritti

- `gene`: l'intera regione genomica occupata dal gene (dall'inizio alla fine, compresi gli introni).
- `transcript` (o `mRNA`): una specifica variante di RNA prodotta da quel gene (un gene può avere più trascritti o "isoforme").

Altre feature

- `exon` (Esone): qualsiasi regione trascritta che rimane nell'mRNA, ovvero nel trascritto. Include sia parti che diventeranno proteine, sia parti che non lo faranno (splicing alternativo).
- `CDS` (Coding Sequence): rigorosamente **solo** la porzione dell'esone che viene effettivamente tradotta in proteina.
- `UTR` (UnTranslated Region): le estremità (5' o 3') dell'RNA che sono trascritte (sono esoni) ma **non** tradotte.
- `start_codon` / `stop_codon`: le coordinate esatte (3 basi) in cui la sintesi proteica inizia o si arresta.

Rappresentazione Visiva GTF

Le coordinate sul Genoma

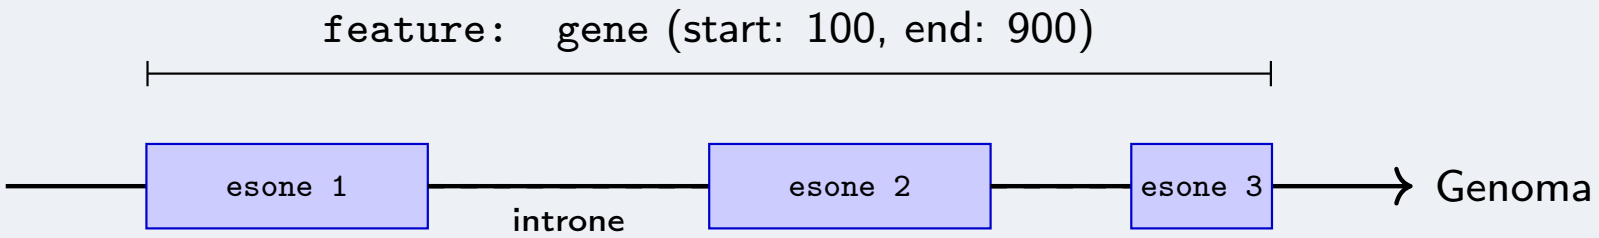

Esempio di un record GTF (Esone 1)

```
chr1  HAVANA  exon  100  300  .  +  .  gene_id "ENSG01"; transcript_id "ENST01";
```

Uso dei Grafi

```
--CTCACTTAGAGGGGCTCTCGACC-GTGTCCAGA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCC----CACTGG
CCCTCACTTAGACCGGCTCTCGACCCGTGTCCAAACCACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
```

Uso dei Grafi

```
--CTCACTTAGAGGGGCTCTCGACC-GTGTCCAGA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCC----CACTGG
CCCTCACTTAGACCGGCTCTCGACCCGTGTCCAAACCACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
```

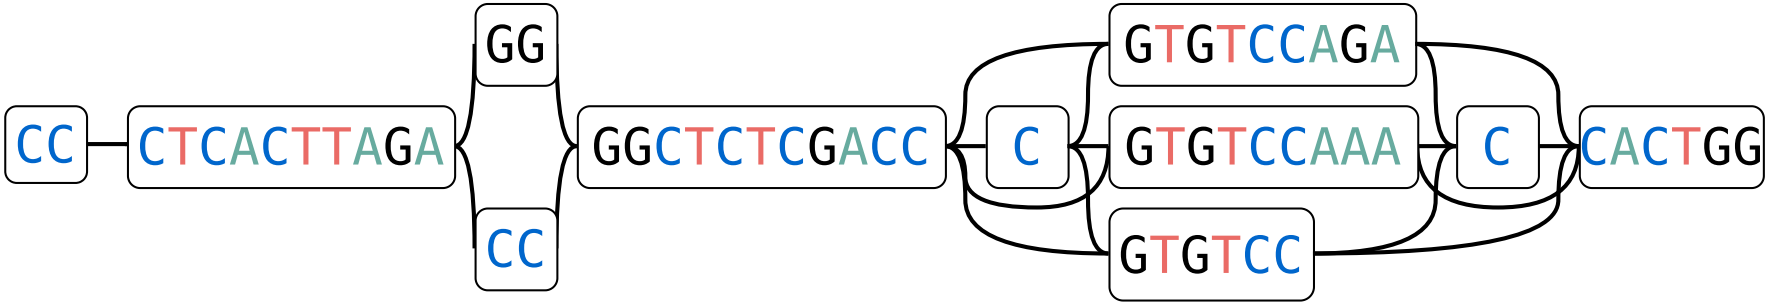

Uso dei Grafi

```
--CTCACTTAGAGGGGCTCTCGACC-GTGTCCAGA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCC----CACTGG
CCCTCACTTAGACCGGCTCTCGACCCGTGTCCAAACCACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
--CTCACTTAGACCGGCTCTCGACC-GTGTCCAAA-CACTGG
```

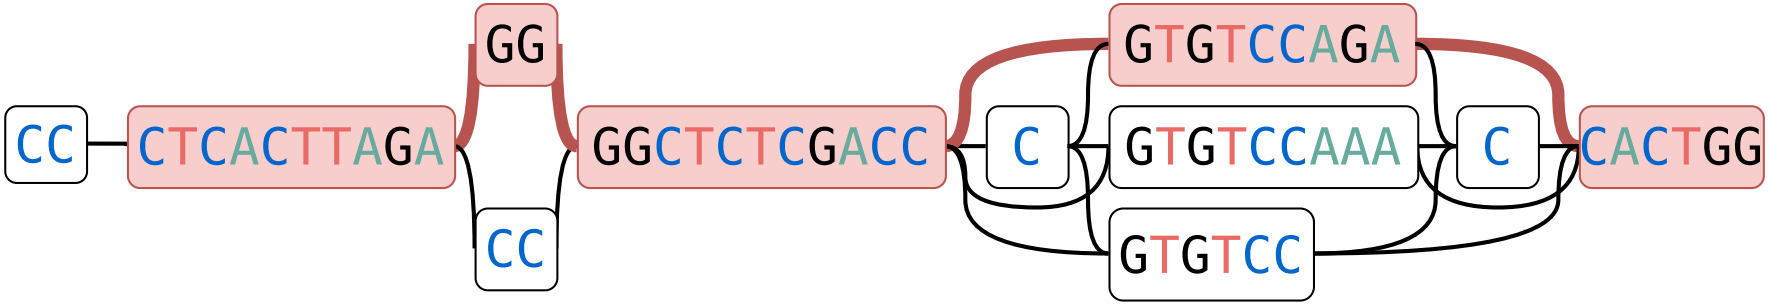

Il Formato GFA (Graphical Fragment Assembly)

Pangenomica e Grafi

Proposto nel 2014 per superare i limiti delle sequenze lineari. Il GFA memorizza **grafi etichettati** in formato testo. È lo standard per gli assemblaggi e i pangenomi.

Struttura Generale

I file sono delimitati da *Tab*. La prima lettera di ogni riga ne definisce il tipo:

- `H` (Header): intestazione e metadati.
- `S` (Segment): i nodi del grafo (le sequenze).
- `L` (Link): gli archi per indicare ordine in cui ricostruire le sequenze.
- `P` (Path): i percorsi attraverso il grafo (utili per ricostruire le sequenze in input).

A fine riga possono esserci campi opzionali testuali o numerici

I Record del GFA: Nodi, Archi e Percorsi

S: segment

Tre colonne: **Tipo** (S), **ID** del nodo, **sequenza**.
Esempio: `S 1 ATGC`

L: link

Sei colonne per collegare due nodi:

1. Tipo (L)
2. ID nodo di partenza e Orientamento (+ o -)
3. ID nodo di arrivo e Orientamento (+ o -)
4. Overlap: Stringa CIGAR (oppure $*$ se non c'è sovrapposizione)

P: path

Quattro colonne: **Tipo** (P), **nome** del percorso, lista di **nodi attraversati** (con orientamento, separati da virgola), e lista degli **overlap** (o $*$).

I Record del GFA: I Walk (Percorsi Pangenomici)

Walk (`W`)

Introdotti nel GFA 1.1, i **walk** sono l'evoluzione dei path.

Struttura del Walk (7 Colonne Obbligatorie)

1. **Tipo:** `W`
2. **Campione:** nome dell'individuo analizzato (es. `Paziente_A`).
3. **Aplotipo:** indice numerico (es. `1` o `2` per organismi diploidi).
4. **Sequenza:** cromosoma o contig di riferimento (es. `chr1`).
5. **Inizio** e **6. Fine:** coordinate genomiche (es. `0` e `7`).
6. **Il Percorso:** lista super-compatta dei nodi con orientamento: > per forward, < per reverse (es. >1>2<3).

Visualizzazione ed Esempio Pratico (Path vs Walk)

Grafo: Due aplotipi diversi

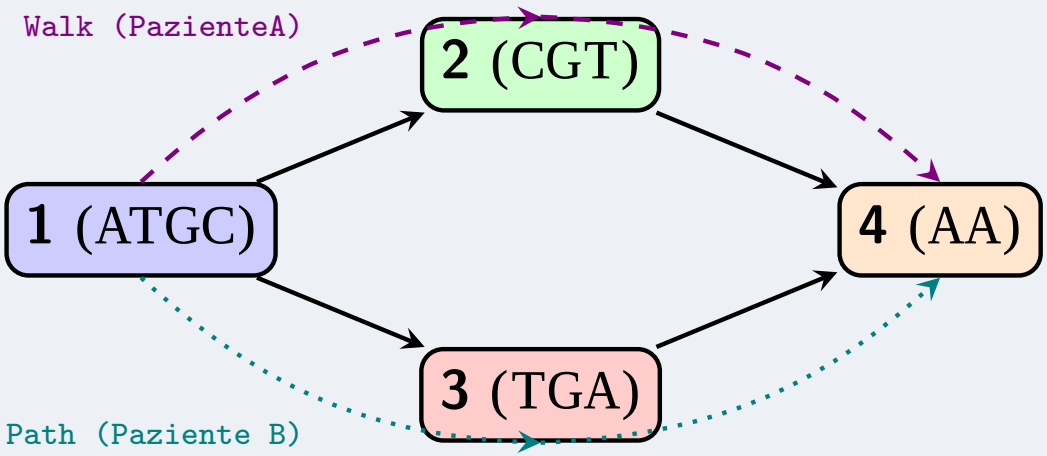

Codice GFA (Due percorsi alternativi)

```
H VN:Z:1.1
S 1 ATGC
S 2 CGT
S 3 TGA
S 4 AA
L 1 + 2 + *
L 1 + 3 + *
L 2 + 4 + *
L 3 + 4 + *
P PazienteB 1+,3+,4+ *,*
W PazienteA 1 chr1 0 9 >1>2>4
```

Graph Alignment Format: GAF e GAM

Allineamento sui grafi

Mentre il SAM allinea i read su una sequenza lineare, il **GAF** memorizza allineamenti di tipo *string-to-graph*.

Il formato GAM (Binary Variant)

Esattamente come il SAM ha il BAM per ottimizzare spazio e prestazioni, il GAF testuale ha la sua controparte binaria chiamata **GAM** (Graph Alignment/Map).

Struttura del GAF

File delimitato da Tab. Ogni riga rappresenta un allineamento e richiede **12 campi obbligatori**, seguiti da eventuali tag opzionali.

I Campi del GAF (1/2): Il Read e il Percorso

Info sul Read (Col. 1-4)

1. **Nome:** identificativo del read (es. dal FASTQ).
2. **Lunghezza Read:** totale delle basi.
3. **Start (Read):** inizio dell'allineamento sulla read (base 0).
4. **End (Read):** fine dell'allineamento sulla read.

Il Percorso nel Grafo (Col. 5-7)

5. **Strand:** direzione rispetto al percorso (+ o -).
6. **Path (Subpath):** la concatenazione dei nodi attraversati, con orientamento > (forward) o < (reverse). *Es: >1>2*.
7. **Lunghezza Path:** somma delle basi di tutti i nodi del percorso.

I Campi del GAF (2/2): Coordinate e Qualità

Coordinate sul Grafo e Statistiche (Col. 8-12)

8. **Start (Path):** inizio dell'allineamento sul subpath.
9. **End (Path):** fine dell'allineamento sul subpath.
10. **Matches:** numero di match.
11. **Block Length:** lunghezza totale del blocco di allineamento.
12. **MapQ:** qualità di mappatura (0-255, come nel SAM).

CIGAR (`cg:Z:...`)

Come nel SAM, usano la sintassi `TAG:TIPO:VALORE`.

- La CIGAR non è obbligatoria nel GAF (le col. 10 e 11 bastano per allineamenti semplici), ma se presente è espresso come `cg:Z:CIGAR`.
- *Es:* *`cg:Z:5M2I3M`* (Z sta per stringa).

Visualizzazione GAF: Allineare un Read al Grafo

Esempio: Read "TGCCG" mappato sui nodi 1 e 2

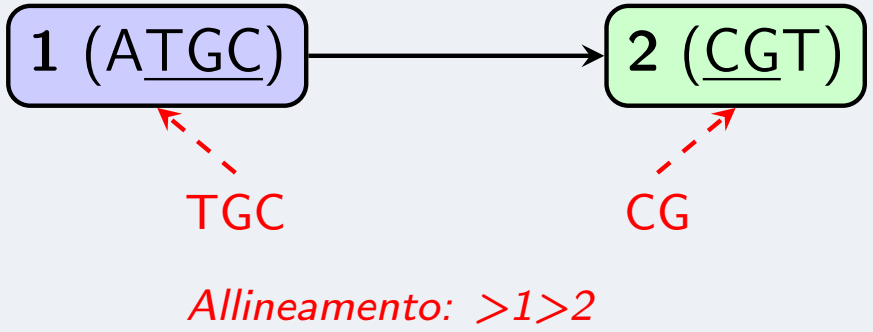

GAF Record

```
read_01  5  0  5  +  >1>2  7  1  6  5  5  60  cg:Z:5M
```

Decodifica dell'esempio

La read (lunga 5) si allinea sul path >1>2 (lungo 7). L'allineamento salta la 'A' iniziale del nodo 1, partendo da offset 1 e finendo a 6, con 5 Match (`cg:Z:5M`).

Biobanche

National Instituted of Health e National Center for Biotechnology Information

- Accesso ad una miriade di dati biologici
- Dati umani ma anche di altre specificamente

Biobanche

UK Biobank

Studio su **500000** cittadini britannici con dati genomici e dati clinici.

Progetto "All of Us" (NIH, USA)

Obiettivo: raccogliere dati genomici e clinici di **1 milione** di americani.

- Focus cruciale sulla **diversità**: coinvolge popolazioni storicamente sottorappresentate (superando i bias etnici dei vecchi database).
- Produce e archivia *petabyte* di file **BAM** e **VCF**.

Human Pangenome Reference Consortium

L'HPRC è un progetto internazionale nato per sostituire il genoma lineare con un **pangenoma a grafo**.

- **Obiettivo:** Sequenziare almeno 350 individui (700 aplotipi) da diverse popolazioni mondiali usando long-read (PacBio, Nanopore).
- **Risultato:** Creare un pangenoma di riferimento che contenga tutta la diversità umana conosciuta in un'unica struttura dati.

Link Utili

- https://www.ncbi.nlm.nih.gov/
- https://www.ncbi.nlm.nih.gov/datasets/genome/GCF_000001405.40/
- https://www.internationalgenome.org/
- https://humanpangenome.org/
- https://www.ensembl.org/index.html

```
curl -L https://ftp.1000genomes.ebi.ac.uk/vol1/ftp/release/20130502/\
ALL.chrX.phase3_shapeit2_mvncall_integrated_v1c.20130502.genotypes.vcf.gz

wget https://ftp.ncbi.nlm.nih.gov/genomes/all/GCF/000/005/845/\
GCF_000005845.2_ASM584v2/GCF_000005845.2_ASM584v2_genomic.fna.gz
```

Prossima lezione

Alcuni tool fondamentali (non vedremo/useremo tutti)

- seqtk
- hifiams
- wgsim
- STAR
- BLAST
- bwa
- maaft
- samtools
- bcftools
- snakemake
- ...